

基于卷积神经网络的绝缘子检测与识别

摘要：对绝缘子故障的例行巡检对于保障电网输电线路的安全运行十分必要。本文把无人机航拍技术引入到日常的输电线路巡检工作中，提出了一种基于无人机航拍图像的输电线路中绝缘子的识别与状态检测方法，可以提高输电线路巡检信息处理的实时性。绝缘子检测算法的设计是决定无人机航拍绝缘子巡检系统的有效性的关键环节。本文首先通过选择性搜索算法对绝缘子图片进行目标建议，提出采用卷积神经网络(CNN)进行自动特征提取结合 softmax 分类器的方法对输电线路绝缘子图片进行绝缘子检测。其采用自制的绝缘子样本库对卷积神经网络进行了训练，并将该方法与传统的特征提取加分类器，以及采用 PCA 特征降维结合全连接神经网络的方法进行了比较。实验结果表明：采用卷积神经网络的绝缘子特征提取取得了最好的绝缘子识别率，对于复杂的背景具有良好的鲁棒性。克服了传统图像处理和传统神经网络识别方法受拍摄角度，光线照，影响的缺陷，实现了绝缘子的 86% 以上的高检测率。针对绝缘子图片中通常含有复杂背景的特点，本文在绝缘子被成功提取的基础上提出采用已训练好的 CNN 网络通过反卷积运算来重构图片中的绝缘子信息并滤除复杂的背景信息。随后进行超像素分割并建立绝缘子数学模型，最终实现了绝缘子串缺陷部位的精准识别。本系统为输电线路无人机巡视中的人工智能巡视提供了借鉴。

关键词：绝缘子；选择性搜索；分类器；神经网络；卷积神经网络；自爆缺失

1. 引言

输电线路担负着电力输送的重要职责，对它的定期巡检是实现输电线路状态检测的主要手段，对保证电网的安全运行具有特别重要的意义。而绝缘子是输电线路中极为重要且用量庞大的部件，起到电气绝缘及机械支撑作用；同时绝缘子终年暴露在野外，遭受着自然天气、自然灾害，机械负荷以及人为因素的损害，属于故障多发元件，其表面表面缺陷严重威胁电网的安全运行。

绝缘子的成功检测可作为无人机进行细节巡视时的标志，利用相机成像的原理，实时测出无人机相对于铁塔的相距，避免无人机误撞的危险，为无人机的避障飞行提供可靠的依据，灵活完成巡检任务。本章节分别采用 3 种具有代表性的图像的目标检测方法，对相同的绝缘子样本进行了实验测试。并对 3 种检测方法进行了分析比较。这些工作为输电线路的智能巡检的检测方法优选提供了实验依据。

绝缘子缺陷检测对于输电线路故障诊断提供了重要的依据。本算法在已训练好的 CNN 模型的基础上，通过反卷积、反池化等运算，将绝缘子信息重构，并弱化背景信息，最后通过超像素分割和绝缘子建模等过程将绝缘子缺陷位置识别出来。本算法充分利用了 CNN 网络的重构能力，克服了采用传统图像处理方法进行检测易受背景影响的缺陷，同时又巧妙低利用绝缘子检测的训练的参数，使得绝缘子检测与缺陷识别实现权值共享，提高了算法运行效率。

2. 绝缘子检测系统设计

图 1 为输电线路绝缘子检测与识别整套算法示意图。在输出结果的图片中，黄色框内标记的为正常绝缘子，红色框标记的为存在缺陷的绝缘子。

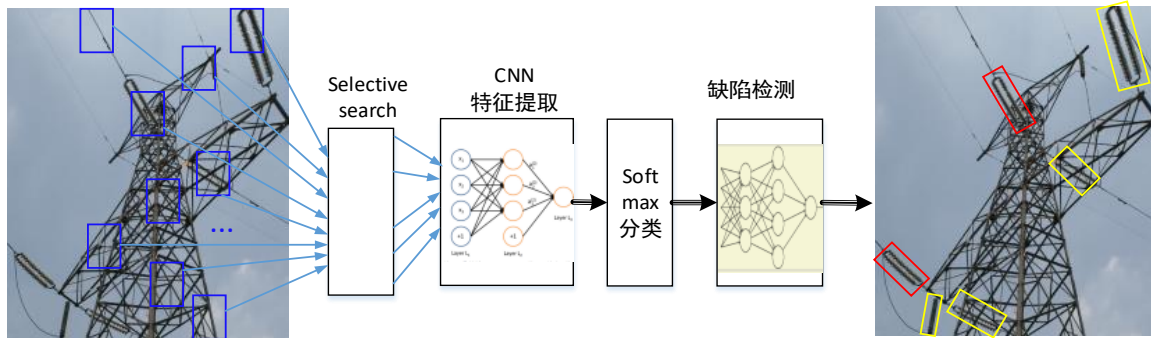


图 1.1 绝缘子检测和自爆识别算法总体结构框图

上图为基于神经网络的输电线路绝缘子检测与识别的整套算法示意图。`selective search` 用于提取原图中物体，这些物体如原图中蓝色框所示，既包含绝缘子又包含非绝缘子，经过预处理环节后，将 `selective search` 拾取的物体中的绝缘子筛选出来，当然不一定 100% 地将绝缘子筛选出来，且筛选出来的绝缘子中有的是部分绝缘子，有的是绝缘子整体。因此本文设计了第三个环节：利用神经网络将绝缘子整体识别出来，与此同时该神经网络进一步将非绝缘子物体剔除掉，以确保该神经网络识别的结果尽量都是绝缘子整体。利用神经网络识别的绝缘子整体中可能有含有缺陷的。因此本文又设计了第二个神经网络来分辨出识别出的绝缘子中含有缺陷的绝缘子。最后输出结果的图片中，黄色框内标记的为正常绝缘子，红色框标记的为存在缺陷的绝缘子。经过这样多个环节的处理就完成了复杂的绝缘子检测与识别的任务。同时也可以看出每一层的处理对上一层未完全筛选的结果进行进一步处理。使得最终结果更加准确。

样本的获取的制作

由于航拍输电线路图片中真正包含绝缘子串部分的图片较少，能够通过人工截取得到的绝缘子正样本相当有限，且在真实的航拍环境下，受拍摄角度、距离，光照等因素的影响，同一绝缘子串在图片中出现的位置，角度是千变万化的。而训练分类器或者神经网络都需要大量的训练样本才可以充分的训练更新每一个参数，为了获得更多的训练样本，对原始样本进行了一定处理以产生新的样本是不可避免的。

本文所采用的航拍绝缘子图片在户外、运动的情况下拍摄的，采集到的图像容易受到光照强度、拍摄角度、方向变化、噪声等因素影响，因此本文采用对截取的样本调整图片亮度、加入噪声、旋转等操作来扩充样本，将样本扩充 7 倍。综上，总体的样本处理方式如下：




图 1.2 样本生成示意图

经过上述的处理，可将绝缘子样本扩充至原来的 9 倍。

绝缘子图像获取及定位分割

基于 CNN 的绝缘子识别

训练样本集预处理

卷积神经网络的结构设计

卷积神经网络的模型参数远大于或者小于数据量时都容易形成过拟合和欠拟合的问题，并且越大的网络模型中含有的参数越多，就越是难以训练。因此应当尽可能的使模型参数与数据量相匹配。考虑到本文特定的识别对象为无人机航拍输电线路中具有明显特征的绝缘子、训练数据的复杂度以及实时性等需求，目前主流的 CNN 网络结构一般采用 5 层结构，如 LENET-5, ALEX5。设计层数越深需要迭代的次数越多才能使学习到的特征收敛。考虑到训练的难度，本系统采用 3 个卷积层，4 个池化层，和 1 个全连接层搭建的网络模型及参数如图 2 所示。

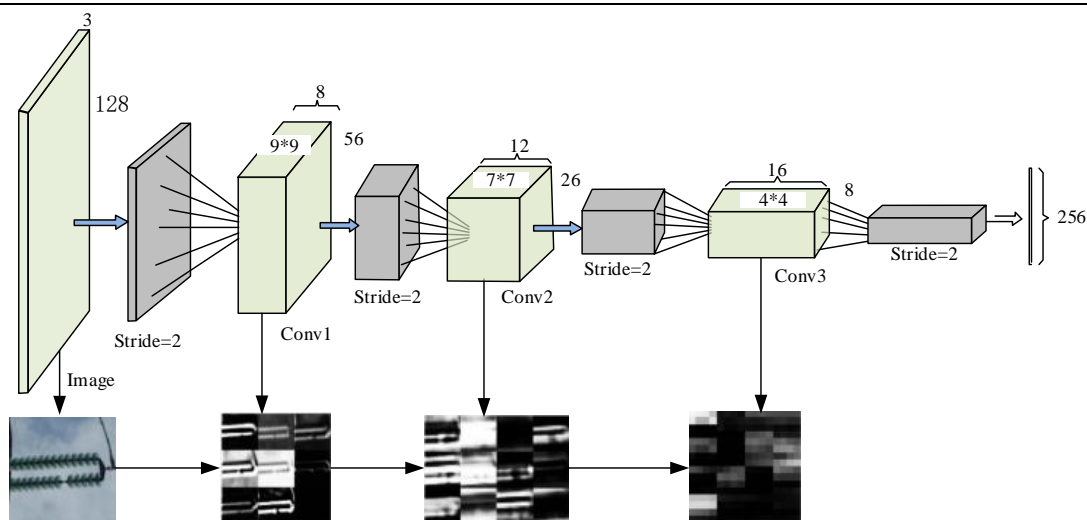


图 1.3 卷积神经网络的参数模型

各层参数设置如下：结合近年来网络模型调参的最新技术，本文网络的详细信息如下：

- 1) 将卷积核的大小进行缩小，采用 9×9 、 7×7 、和 4×4 的卷积核进行卷积以获取更详细的局部信息；
- 2) 每一层的 采用 ReLU 激活函数；
- 3) 分类器采用二分类的 Softmax 分类器。

卷积神经网络的训练

训练用于绝缘子特征提取的卷积神经网络的目的是为了调整每一层卷积核的参数，使得每一层的卷积核仅仅对绝缘子的特征敏感。







图 1.4 不同学习率下的训练和测试正确率，样本均差随迭代次数的变化，2 层和 3 层卷积神经网络样本均差随迭代次数的变化

由上图可分析出，最佳的学习率为 0.016，学习率设置过低，训练时间过长（迭代次数大于 200），还会导致网络无法收敛到最佳状态。学习率设置过高，网络也无法收敛到最佳状态。CNN 层数越多，网络越难收敛，训练时间越长。实测发现训练 4 层卷积需要的循环次大约为 50 个 epochs，约 9000 次迭代，总共需要时间约为 4 小时。从高层网络的变化过程，可以看到，刚开始几次的迭代，基本变化不是很大，但是到了 40~50 的迭代的时候，变化很大，因此我们以后在训练网络的时候，不要着急看结果，看结果需要保证网络收敛。

绝缘子自爆缺失识别

由于绝缘子长期暴露在自然环境中，不仅要承受导线和金属附件的重量，还要承受恶劣天气下的风压载荷、冰雪载荷、导线舞动以及雷击等各类冲击负荷。钢化玻璃绝缘子因其具有零值自爆特性、减少人工测零工作以及自爆不掉串等优点，目前已在输电线路获得了广泛的应用。零值自爆指的是钢化不良或含有杂质的玻璃体在机械、电气、冷热等负荷的作用下自行破碎的现象。检查线路时可以轻易的发现已经自爆的绝缘子，不需要再花费大量的工作时间去按周期检测和判断绝缘子的零值，这样既节省了大量的交通车辆费用，也节省了外勤人员旅差费的开支。引起绝缘子自爆的原因有以下几种：

（1）生产玻璃绝缘子的厂家较多，由于制造设备、工艺不一样，所以有部分因素来自制造过程中玻璃中的杂质和玻璃结瘤。若杂质和结瘤分布在内张力层时，在产品制成或运行一段时间后，部分不合格玻璃绝缘子就会发生自爆。若杂质或结瘤分布在外压缩层，在输电线路运行一段时间后，在遇到强烈的冷热温差和机电负荷作用下，有可能引发玻璃绝缘件自爆。

（2）绝缘子以玻璃构件为主要元件，在绝缘子存放、运输过程中，由于随意安放、碰撞，容易引起玻璃构件的玻璃张应力层及机械强度受到破坏，投运后在电压作用下更容易引起自爆。

（3）运行中玻璃绝缘子的污秽层表面受潮后，在工频电压作用下会发生局部放电。由局部放电引起的长期发热会导致玻璃件绝缘下降，引起零值自爆。所以在污秽严重地区运行的玻璃绝缘子其自爆率会有所增高。自爆是重污和湿润条件下表面泄漏电流造成产品局部受热而引起的热击穿现象。

（4）外力破坏、施工后，主要是安装时受施工器械外力、在运行中遭受外力（鸟枪、弹弓袭击）破坏时，也可引起绝缘子自爆。

自爆缺失检测方法

绝缘子的裂纹既可在巡视时进行检查，也可在停电时检查。传统的检查的方法有：（1）目测观察。绝缘子的明显裂纹，一般在巡线时肉眼观察就可以发现。（2）望远镜观察。借助望远镜进一步仔细察看，通常可以发现不太明显的裂纹。（3）声响判断。如果绝缘子有不正常的放电声，根据声音可以判断是否损坏和损坏程度。（4）停电时用兆欧表摇测其绝缘电阻，或者采用固定火花间隙对绝缘子进行带电测量。十九、污秽闪络的形式及危害，防止污秽闪络事故的措施。

在图像处理中，神经网络是被使用最多的一种算法，由于图像处理技术依托于机器自动对采集

到的图像进行判断、识别，而对于同一绝缘子 采集到的图像也会受到拍摄角度、方向 、遮挡、照明等影响，使得缺陷与背景光带的面积、相对位置、重合关系会有明显的差异， 如单纯以形态学方法检测容易出现误检、漏检，往往无法达到预期的目标. 神经网络的自学习性在这里就体现出它的优势，通过大量的训练，可以让系统对各种不规则形状进行有效的鉴别。

基于卷积神经网络的缺陷检测

利用多旋翼无人机良好机动性和操控性，通过搭载的高分辨率遥控相机从多角度近距离拍摄目标图像，获取不同类别的缺陷的关键细节。这些多角度的关键细节是人工巡视无法获取的。通过高清数字图传设备将拍摄的影像传输至地面监控站可供工作人员进行细节查看。但是采用人工方式判断巡检视频是否存在绝缘子隐患或故障，效率底下且可能造成人为偏差【1】。因此有必要在地面监控站开发绝缘子故障诊断系统，智能判断故障，提升巡检智能化水平。由于季节更替，天气变幻，地形气候复杂，导致航拍背景复杂多变。加上无人机航拍角度多变及尺度多变的影响，使得许多传统基于浅层学习的算法的鲁棒性不高，工程应用受限【1】。同时，绝缘子自爆图像样本相对正常样本数量而言，样本量太小，不满足深度卷积神经网络对训练数据量的要求，因此需设计针对绝缘子自爆识别的算法。深度网络结构是手段，特征提取是目的，因此可利用 CNN 神经网络对绝缘子的特征提取和识别能力，从复杂的航拍背景中智能地分割出待检测的目标。相比传统的基于图像的形态学，颜色空间转换提取，阈值分割等方式更直接有效。

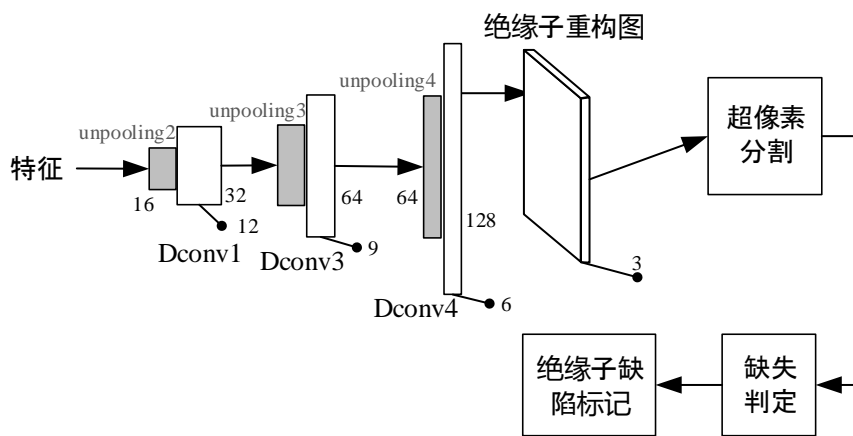


图 1.5 绝缘子自爆缺陷图像识别过程

结合 CNN，将卷积层处理得到的特征图，经反卷积运算后得到尺寸统一的绝缘子的显著图。其滤除的背景和保留的绝缘子将更加精确和清晰。然后利用超像素算法将图像细分为多个图像子区域，通过对图像中的每个像素加标签使得具有相同标签的像素具有某种共同视觉特性，实现对单个绝缘子像素的聚合，目的是为了得到单个绝缘子的轮廓。

绝缘子重构

绝缘子检测是利用 CNN 对目标物体进行特征提取，属于卷积神经网络的正向过程。正向过程就是对目标进行编码的过程。其实还可对训练的 CNN 网络进行反卷积运算，反卷积则是对目标进行信息重构的过程。反卷积运算对于从图片中抠取目标具有非常重要的作用。从以上层特征化过程也可以

看出，卷积神经网络每一层上不同的特征图代表了物体不同的属性，因此多层卷积神经网络既能对物体进行特征提取，又能对目标进行重构，且网络中的多层特征能够较为全面反映物体的属性。




图 1.6 利用反卷积网络进行绝缘子重构的示意图

上一章所设计的卷积网络负责特征提取，将输入图片转化为多维的特征向量；而反卷积网络则根据特征提取图片中对象的形状（shape）。最终网络的输出为一个与输入图片相同尺寸的矩阵，表示每个像素属于某一个预定类的概率。本文利用反卷积神经网络对绝缘子进行重构，同时滤除复杂的背景信息，仅保留绝缘子所在区域的信息，以便对绝缘子故障进行分析。

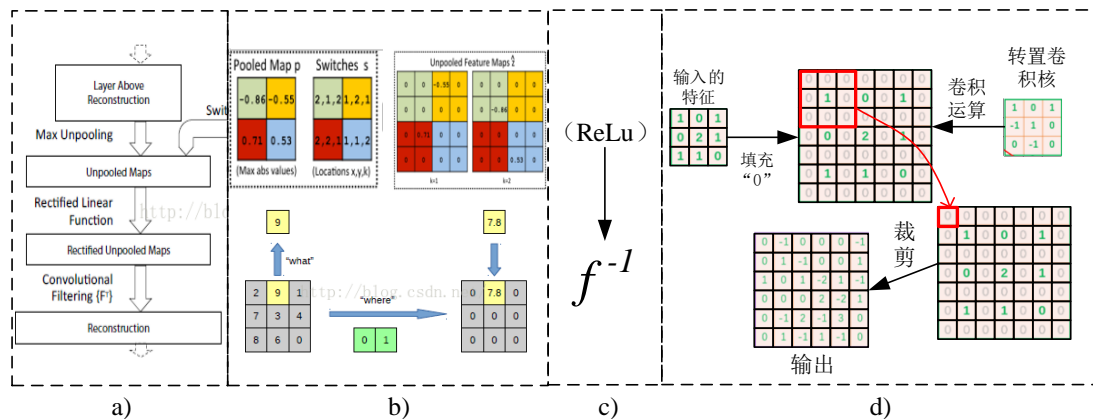


图 1.7 CNN 的反运算过程。a) 总体过程示意图，b) 反池化过程，b) 反激活，d) 反卷积

(1) 反池化

池化是不可逆的过程，然而我们可以通过记录池化过程中，最大激活值得坐标位置。然后在反池化的时候，只把池化过程中最大激活值所在的位置坐标的值激活，其它的值置为 0，当然这个过程只是一种近似，因为我们在池化的过程中，除了最大值所在的位置，其它的值也是不为 0 的。

(2) 反激活

本文所设计的 CNN 中，ReLU 函数是用于保证每层输出的激活值都是正数，因此对于反向过程，我们同样需要保证每层的特征图为正值，也就是说这个反激活过程和激活过程没有什么差别，都是直接采用 ReLU 函数。

(3) 反卷积

对于反卷积过程，采用卷积过程转置后的滤波器(参数一样，只不过把参数矩阵水平和垂直方向翻转了一下)，其实通过以上绘制的反卷积思路图，就已经把原理讲的很清楚了。大致步奏就是，先填

充 0，然后进行卷积，卷积过程跟上一章的卷积过程是一样的。最后一步还要进行裁剪得到统一尺寸。下图是从不同卷积层进过反卷积运算获得的绝缘子重构图，黑色方块是为了显示的方便而填补的一个特征图。

特征可视化

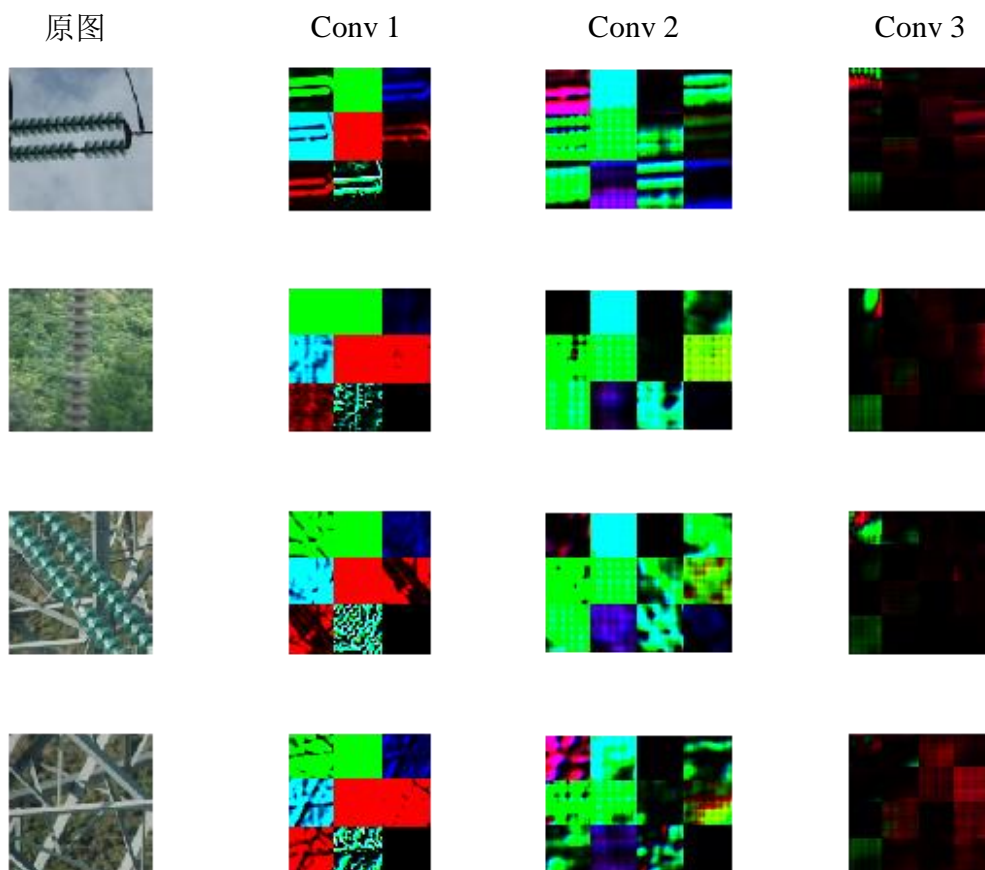


图 1.8 从不同卷积层进过反卷积运算获得的绝缘子重构图

总的来说，通过 CNN 训练后，学习到的特征，是具有辨别性的特征，比如要我们区分绝缘子，那么通过 CNN 学习后，背景部位的激活度基本很少，通过可视化就可以看到我们提取到的特征忽视了背景，而是把关键的信息给提取出来了。从 layer 1、layer 2 学习到的特征基本上是边缘等低层特征；layer 3 则开始稍微变得复杂，学习到的是绝缘子纹理特征，比如上面的一些网格纹理；layer 4 学习到的则是比较有区别性的特征。相关结果如下：

提取特征是数字图像处理中一项非常重要的任务。特征的好坏将会直接影响后续图像分类的准确性。而在传统的图像处理中，大多在研究如何能够提取到更好的特征，如 HOG、SURF 等特征。这些提取特征的算法大多建立在复杂的公式推理之上且需要反复提取各种特征进行验证后才能确定，工作量较大。而深度学习使提取图像特征变得简单，但同时也增加了神秘性。深度学习网络采用的是端到端的数据处理方式，它可以从海量的数据中自动的提取出数据特征，但这些内容就像是一个黑盒子，我们只知道记录了有用的信息，却不知道具体的内容。

卷积神经网络把图像通过卷积与池化后提取到的特征进行前向传播，然后通过网络的输出与数据标签

的差值进行反向传播从而调整网络的参数，从而能够自动的提取出有利于分类的特征。但是由于卷积神经网络的黑盒子性质，增加了优化网络产生的难度。因此学习到的特征可视化出来对调试深度网络的结构以及优化网络参数是很有帮助的。下面将本文设计的卷积神经网络学习到的信息以图像的形式可视化出来。

卷积神经网络和普通的神经网络一样，由神经元按层级结构组成，其间的权重和偏移量都是可训练得到的。将航拍绝缘子图片输入训练好的卷积神经网络模型，分析经过卷积层和池化层处理后的特征图，有助于理解特征的层级组合。

总的来说，通过 CNN 学习后，我们学习到的特征，是具有辨别性的特征，比如要我们区分绝缘子，那么通过 CNN 学习后，背景部位的激活度基本很少，我们通过可视化就可以看到我们提取到的特征忽视了背景，而是把关键的信息给提取出来了。从 layer 1、layer 2 学习到的特征基本上是边缘等低层特征；layer 3 则开始稍微变得复杂，学习到的是绝缘子有区分行的特征，从上图可看出：(1) 对同一个样本进行不同的处理，只会使得网络的低层提出到的特征产生变化，而对高层提取到的特征影响较小；(2) 从层与层之间做比较，我们可以看到，低层在训练的过程中基本没什么变化，比较容易收敛，高层的特征学习则变化很大，比较难收敛，需要较长的时间才能训练好。这解释了低层网络的从训练开始，基本上没有太大的变化，因为梯度弥散。

超像素分割

超像素分割属于图像分割 (image segmentation)。对一幅图像进行超像素分割，分割之后，你得到许多大小不一的区域，你可以从这些区域中提取出有效的信息，比如颜色直方图、纹理信息。例如对人物的图像进行超像素分割，进而通过对每个小区域的特征提取，辨识出这些区域是处于人体的哪个部分（头部、肩部，腿部），进而建立人体的关节图像。另外，如果你要用图论的方法来分离前景背景。如果这幅图的大小为 480×640 ，那么建立的图(graph)有 480640 个节点。如果预先对这幅图像使用超像素分割，将其分割为 1000 个超像素，那么你建立的图只有 1000 个节点。大大提升了计算速度。选择超像素算法时应考虑以下性能：1). 超像素应该有好的图像边界吻合度。2). 当用于减少计算的复杂性时，作为一个预处理步骤，超像素应该可被快速计算，占据较小的内存，和简单的使用。3). 当用于分割的目的时，超像素分割既要能够提高处理速度又要提高搜索结果的质量。




图 1.9 超像素分割效果图

因此，本文采用了一种新型的超像素算法：简单线性迭代聚类（SLIC），它应用 k -means 聚类算法以相似的方法生成超像素[30]。显而易见的是，在伯克利基准中证实 SLIC 在图像边界的吻合度方面不如现有的几种算法[20]，在 Pascal [7] 和 MSRC [24] 数据集分割时优于现有算法。此外，它比起现有方法处理速度更快，占有内存更小。除了这些可量化的优点，SLIC 便于使用，生成大量超像素时简洁灵活，可扩展到更大规模并且易于获得。

自爆缺失判定

通过超像素分割后可得到单个绝缘子的轮廓后，可建立绝缘子串的数学模型。通过求取轮廓的外接矩形求取单个绝缘子的区域坐标 $L(x, y)$ 及其宽度 $width$ 和高度 $height$ ，及绝缘子的个数 N 。对分割出的绝缘子进行轮廓检测，并获得绝缘子的中心。通过对单个绝缘子中心进行最小二乘法直线拟合，得到绝缘子串骨干线 $y = kx + b$ ，计算出与 x 轴的角度 θ 。利用单个绝缘子区域坐标 $L(x, y)$ 和绝缘子串的中心线 $y = kx + b$ ，建立绝缘子的数学模型如图 6 所示。




图 1.10 绝缘子串数学建模

每个绝缘子都带有金具，且尺寸规格相同，在轮廓分割的条件下，绝缘子的区域大小相差不大，区域的面积 $area$ 定义为 $area = width * height$ 。若存在绝缘子自爆故障，则在骨干线上只保留了金具，缺失了盘形绝缘子的玻璃叶片，该区域的面积($area$)将比其他区域面积偏小。经多次计量，可得到存

在绝缘子自爆故障的面积阈值(T_s)。同时, 对每个绝缘子区域进行有效像素比例的统计, 即获取高亮度值的像素个数 $\text{count } i$ 。经反复实际测试, 得到有效像素比例的阈值 T_r 。针对绝缘子自爆故障判定的算法如图 7 所示。

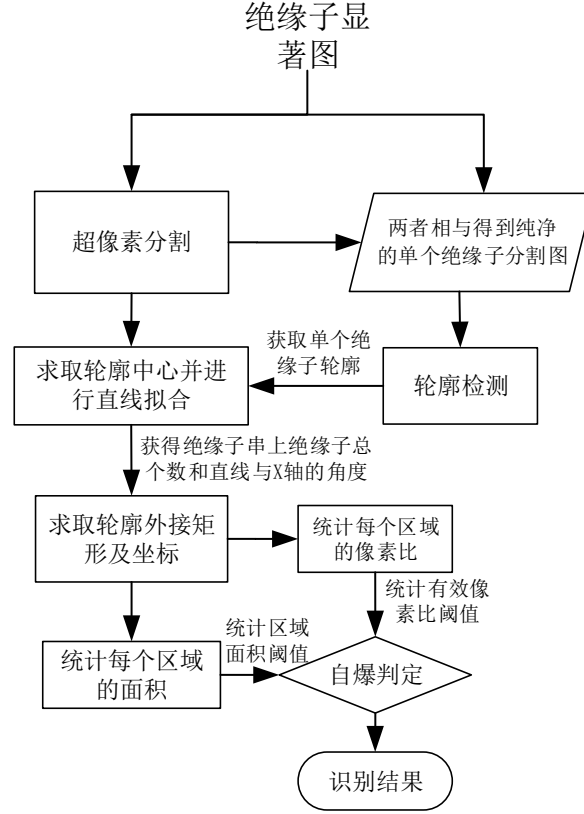


图 1.11 绝缘子自爆缺陷图像识别算法示意图

本文采用的绝缘子自爆特征定位方式是通过先统计标定区域内（外接矩形区域）白色像素点的面积比例和区域面积, 再与预先设定的比例阈值进行比较, 判断是否存在缺失, 判断条件和设定阈值的计算公式和分别为式(5)和(6) 所示。

如式(5)所示。

$$\begin{cases} \left| r = \frac{\text{count}(i)}{s(i)} - \bar{r} \right| \leq r_{th} \ \& \ s(i) \leq \bar{s} & \text{with_defeats} \\ \text{others} & \text{No_defeats} \end{cases} \quad (5)$$

$$T_r = \frac{1}{N} \sum_{i=1}^m r_i, \quad T_s = \frac{1}{N} \sum_{i=1}^m s_i \quad (6)$$

式中: $s_{(i)}$ 代表每个绝缘子的区域面积, $\text{count}_{(i)}$ 为绝缘子的有效像素和, $r_{(i)}$ 代表以第 i 个绝缘子的像素总和与为该绝缘子区域面积有效像素的比例, width 和 height 分别为获取的绝缘子区域的宽和长, N 为该串绝缘子串上获得的区域中心点的总个数。经反复测试, 比例阈值取 0.35 时说明改位置像素偏少, 即反应出该位置绝缘子存在自爆。并标记该位置, 进行输出。该算法简单快捷, 不需要经过图像处理的方法, 直接在提取出的绝缘子图像上即可实施。

3. 实验测试及结果

测试的平台为 Windows 系统, Intel 酷睿 i7 7700HQ 八核, CPU 2.67 GHz, 内存 DDR3 1333 Hz 容量 8 G。

不同算法的比较

为了比较本文所采用的不同检测方法, 对绝缘子的检测的效果, 选取一张含有扁平绝缘子和陶瓷绝缘子的多目标图片。分别采用本文所提供的 3 种检测算法对绝缘子进行识别。目前识别和检测任务大量依赖人工设计特征, 也出现了一些良好的特征如 Haar、SIFT、HoG、LBP 等。传统的识别检测方式针对不同的识别对象, 需设计不同的特征和分类算法, 比如针对人脸检测的经典算法采用 Haar 特征和 Adaboosting 分类器; 针对行人检测的经典算法采用 HoG 特征和 SVM 分类器; 针对一般的物体检测采用 HoG 特征和 PCA 算法^[1]。本文将卷积神经网络检测方式与采用传统的 HoG 特征和 SVM 方式, 及 PCA 特征和 NN 方式做对比。针对同一训练集合, 利用深度卷积神经网络和传统方式的检测效果对比如图 *所示。




图 1.1 绝缘子检测效果对比图

为了测试不同方法对输电线路绝缘子的检测效果, 本文选取了 200 张背景包含树木, 草地, 铁塔和房屋等复杂背景的航拍图像 (所有图片归一化至 128*128), 采用 Navneet Dalal 的 HoG 特征加 SVM 的方式^[2], 和 PCA 降维配合传统神经网络的方式, 和本文所设计的卷积神经网络的方式进行对比测试, 对比结果如表 1 所示。

绝缘子检测对比结果

方法	漏检率/%	误检率/%	平均检测时间/(ms/帧)
HOG+SVM	15.2	12.2	76
PCA+NN	8.8	10.1	95
CNN	6.2	5.3	55

从如图 *所示的识别效果图和表 *所示的绝缘子检测对比结果可看出, 采用传统的图像处理方法

出现漏检和误检的情况的较多，大量的铁搭塔杆被识别成绝缘子。传统的图像处理方法采用手动特征提取，算法简单，但容易受环境因素的影响。采用 PCA 加传统的神经网络方法虽然漏检率和图像处理的方法相比有较大的降低，但也存在较大的误检率，且对绝缘子的空间定位效果差，运行效率低。传统的神经网络节点之间采用全连接方式，网络权值数量较多，使得运行效率变低。传统的神经网络需将二维图片转换为列向量，从而失去了图片的空间信息，导致绝缘子的定位效果变差。CNN 网络结构本身具有权值共享，局部连接等特性相关。本文所采用的 CNN 方式在和检测率、定位效果和检测速度上较前两种方法都有明显的提升。

CNN 训练效果

目标检测领域常采用 AP (average precision), Recall, IOU 等指标对训练效果进行评价，Matlab 可以直接调用 vl_feat 中的 vl_pr。VLFeat-Tutorials 这里面详细地给出了概念的解释以及计算方式。为了测试 CNN 网络训练的效果，本文选取 10 张含有多个绝缘子的图片。每张图片经过目标建议产生上千个枚举图片，其中有的是绝缘子，有的是背景图片。

绝缘子样本的 CNN 训练效果

阈值 (%)	50	55	60	65	70	75	80	85	90	95
TP	0.15	0.15	0.15	0.15	0.15	0.15	0.15	0.15	0.15	0.15
TN	0.22	0.22	0.22	0.22	0.22	0.22	0.22	0.22	0.22	0.22
FP	0.52	0.52	0.52	0.52	0.52	0.52	0.52	0.52	0.52	0.52
FN	0.15	0.15	0.15	0.15	0.15	0.15	0.15	0.15	0.15	0.15
Precision	0.92	0.89	0.82	0.81	0.71	0.68	0.73	0.71	0.67	0.59
Recall	0.03	0.2	0.5	0.6	0.65	0.70	0.75	0.80	0.91	0.99

注：True positives (TP): 绝缘子的图片被正确的识别成了绝缘子；True negatives (TN): 系统正确地将背景图片识别为背景；False positives (FP): 绝缘子图片被错误地识别成背景；False negatives (FN): 系统错误地将背景图片识别为绝缘子。

Precision 与 Recall

Precision 其实就是在识别出来的图片中，True positives 所占的比率，Recall 是被正确识别出来的绝缘子个数与测试集中所有飞机的个数的比值。二者计算公式如下：

$$\text{precision} = \frac{tp}{tp + fp} = \frac{tp}{n}, \quad \text{recall} = \frac{tp}{tp + fn} \quad (1)$$

Precision-recall 曲线：如果你想评估一个分类器的性能，一个比较好的方法就是：观察当阈值(置信度)变化时，Precision 与 Recall 值的变化情况。




图 1.2 Precision-recall 曲线

如果一个分类器的性能比较好，那么它应该有如下的表现：被识别出的图片中绝缘子所占的比重比较大，并且在识别出背景之前，尽可能多地正确识别出绝缘子，也就是让 Recall 值增长的同时保持 Precision 的值在一个很高的水平。而性能比较差的分类器可能会损失很多 Precision 值才能换来 Recall 值的提高。通常情况下，文章中都会使用 Precision-recall 曲线，来显示出分类器在 Precision 与 Recall 之间的权衡。

CNN 识别结果分析

为了测试本文所设计的算法在多目标复杂背景下的识别情况，分别选取只含有玻璃绝缘子的图片，只含陶瓷绝缘子的图片，对既含有玻璃绝缘子又含有陶瓷绝缘子的图片来进行测试。测试效果如下：

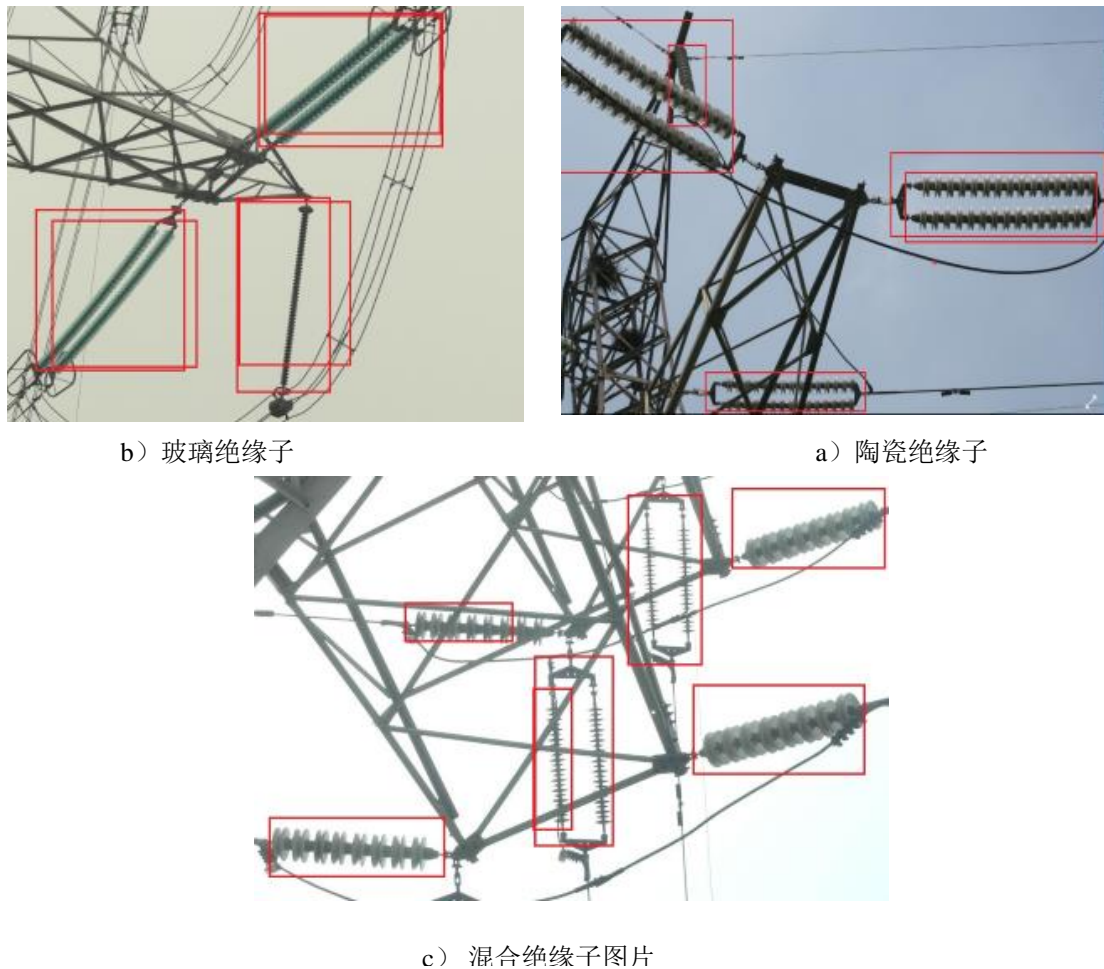


图 1.3

c) 混合绝缘子图片



a) 明亮背景

b) 暗淡背景

c) 近距离拍摄

图 1.4 不同拍摄条件下的绝缘子检测效果，多目标绝缘子测试效果

从样本中选取 300 张航拍绝缘子图像。其中 100 张为玻璃绝缘子图像，100 张瓷质绝缘子图像，100 张玻璃绝缘子和陶瓷绝缘子混合的图像。测试效果如图 8 所示，从上图不同算法的检测效果比较可看出，测试结果表明，针对单一的玻璃绝缘子或者瓷质绝缘子，亦或是二者混合的情况，都表现出对多角度绝缘子的良好检测效果。

为了测试在不同光照，不同拍摄角度的情况下，CNN 识别算法对绝缘子的检测效果，本文选取了不同光照亮度和不同拍摄距离条件下的绝缘子图片作为测试图片，检测效果如下图所示。

从图* 可看出, 针对同一时间段, 同一巡视场景, 在不同光照, 多尺度和多角度拍摄情况下, 对航拍铁塔上的同一串绝缘子检测效果优良。

从以上对 CNN 检测效果的分析可看出, CNN 对绝缘子图片的拍摄距离、角度, 以及光照的变化表现出良好的适应性。这些与 CNN 网络结构本身具有权值共享, 局部连接等特性相关。

绝缘子自爆图像识别算法测试采用 100 张航拍绝缘子图像 (如图 5.1 所示), 其中 50 张为简单背景下的绝缘子航拍图像, 另外 50 张为复杂背景下的绝缘子航拍图像。每 100 张测试图片照片中, 含有缺陷和无缺陷的样本各 50 张。

缺陷检测实验硬件平台与上一张绝缘子识别一致。测试过程中, 用存在缺陷的样本来测试识别率与漏识率, 用不存在缺陷的图像测试误识率。

缺陷识别过程

为了将缺陷检测全过程直观地体现出来, 将反卷积运算得到的绝缘子显著图, 经过像素分割后的结果图, 经过绝缘子判定算法获得的绝缘子模型图和最终的缺陷位置标记图整理绘制, 如图 5.9 所示。

如图 5.9 b) 所示, 经过反卷积运算, 已经能够将图片中绝缘子部分的信息凸显出来, 而将绝缘子的背景信息弱化。如图 5.9 d) 所示, 经过超像素化处理并与回归后绝缘子显著图相与后, 绝缘子轮廓被显示出来, 同时绝缘子部分也被分割成若个小块以便于后续进行快速处理。如图 5.9 e) 所示, 通过本文所设计的绝缘子模型算法可将绝缘子串中的单个绝缘子分离出来。如图 5.9 f) 所示, 利用本文所设计的绝缘子缺陷判定算法, 将绝缘子缺陷位置标记出来。

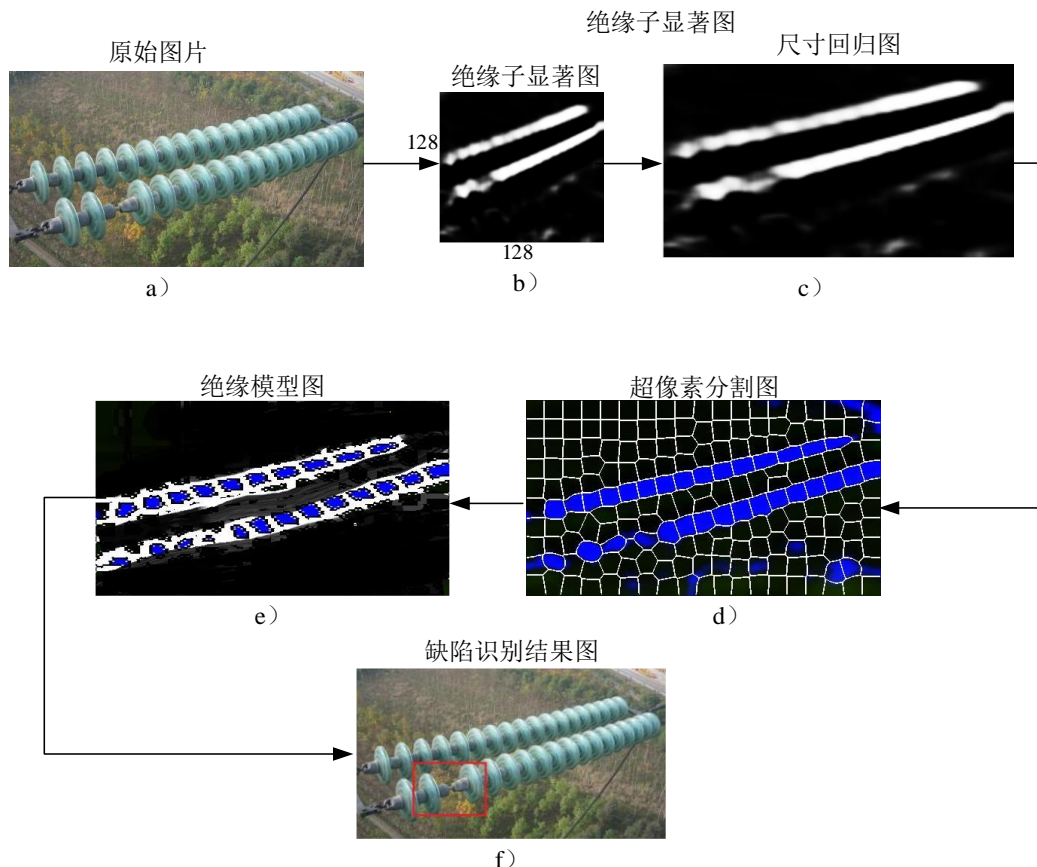


图 1.5 绝缘子缺陷识别过程， a) 绝缘子原图，b) 反卷积运算后的绝缘子显著图，c) 尺寸回归图 d) 超像素分割图 e) 单绝缘子分离图 f) 缺陷识别结果图。

缺陷识别率测试

在所有测试样本上（包含简单背景样本和复杂背景样本）采用本文所设计的算法试验 3 次，针对简单背景和复杂背景两类样本分别统计缺陷的识别率和无缺陷的误识率。统计结果如下：

缺陷检测实验结果（%）

测试分类	缺陷图像的识别率	无缺陷图像误识率
简单背景	85.2	6.8
复杂背景	81.6	8.2

在简单背景下(天空，地面)，采用绝缘子颜色特征或者边缘形状特征等传统识别算法的准确率与本算法识别准确率均可达到 80% 以上，而在复杂背景下，由于卷积神经网络强大的特征学习能力，其获得的显著图能快速地排除复杂背景，准确地分割出待识别的绝缘子目标，识别准确率仍达到 80% 以上，与传统的人工设计绝缘子特征进行绝缘子分割的方法相比，识别效果表现出其优势。但对部分受拍摄角度影响的图像，导致自爆区域被掩盖，仍存在漏检情况，试验结果如表*所示。

4. 总结

本文采用卷积神经网络对输电线路绝缘子进行特征提取，实现了绝缘子的有效识别。在此基础上又通过卷积神经网络的反运算功能对绝缘子信息进行重构，同时滤除复杂背景信息，随后采用后续的图像处理方法实现了绝缘子缺陷的有效检测。对本文研究工作的总结和未来将进一步开展的研究如下：

(1) 样本制作

对于任何神经网络算法，样本的质量是决定神经网络识别效果好坏的关键因素。对于绝缘子样本来说，样本既要丰富全面，又要能反应绝缘子目标的特征。尽量截取含有复杂背景的绝缘子图片

(2) 绝缘子检测

在确定好卷积神经网络的层结构后，对每一层的卷积核数量的设置，不应过多，网络参数设置，过多容易导致过拟合，使得网络泛化能力差；卷积核数量过少容易使网络欠拟合，容易出现绝缘子误检。

(3) 缺陷识别

本文所采用的绝缘子缺陷识别算法在已训练好的 CNN 模型的基础上，通过反卷积、反池化等运算，将绝缘子信息重构，并弱化背景信息，最后通过超像素分割和绝缘子建模等过程将绝缘子缺陷位置识别出来。本算法充分利用了 CNN 网络的重构能力，克服了采用传统图像处理方法进行检测易受背景影响的缺陷，同时又巧妙低利用绝缘子检测的训练的参数，使得绝缘子检测与缺陷识别实现权值共享

在这里必须说明的是绝缘子检测是在目标建议后进行的。目标建议的性能直接影响到绝缘子检测效果。本文所采用 selective search 算法对一幅完整图片所产生的目标建议数量为 2000 个左右。训练好的 CNN 网络需要对每个建议区域图像进行特征提取，运行效率低下。因此本文所设计的算法运行效率的低下，这也是本文算法的缺陷所在。

本文所研究的课题可归结目标检测领域的一个应用。对于目标检测有很多开源的算法可供参考。如RCNN、Fast-RCNN，Faster-RCNN和Mark-RCNN【】。

未来将参考Faster-RCNN 框架^[2]，利用CNN提取的特征构建Region Proposal Network (RPN)。该 RPN是一个完全卷积网络，同时预测对象边界和每个位置的目标分数。 RPNs是端对端进行训练，可生成高质量的目标建议，CNN用于检测。RPNs 和CNN通过一个简单交替进行优化，并训练RPN和CNN共享卷积特征。如果采用这种算法，那么对一幅完整图片仅仅需要进行一次特征提取。

同时也要参考一下目前最新的目标检测技术：MARK-RCNN。该开源框架不仅能实现对目标的检测，还能对目标进行分割，且检测和分割同步进行。借助该技术，我们再识别绝缘子的同时，还可将绝缘子串的轮廓输出，以便于进行故障诊断。该技术所实现的目标检测和分割功能正是绝缘子检测和缺陷识别需要。